

Universidad Tecnológica de Querétaro
División de Automatización e Información
Ingeniería en Gestión de Desarrollo de Software

Evaluación de la Unidad 2

Extracción de Conocimiento de Base de Datos

Análisis Supervisado y No Supervisado

Reporte de algoritmos de regresión, clasificación, agrupación, reducción de dimensionalidad y herramienta alternativa

Materia: Extracción de Conocimiento de Base de Datos
Docente: Filiberto Ruíz Hernández
Semestre: 2026
Alumno: Ramírez Martínez Mario Alberto
Matrícula: 2023371044
Fecha: 2026-08-07

Datasets: beisbol.csv, breast-cancer.csv, samsung.csv,
comprar_alquilar.csv

Índice

1	Introducción	4
1.1	Objetivo	4
1.2	Conjuntos de datos	4
1.3	Repositorio	4
2	Análisis Supervisado 1 — Regresión sobre beisbol.csv	4
2.1	Justificación del algoritmo	4
2.2	Diseño del modelo (paso a paso)	5
2.3	Evaluación y optimización	5
2.4	Gráficas e interpretación de resultados	6
2.5	Enlace al modelo	7
3	Análisis Supervisado 2 — Clasificación sobre breast-cancer.csv	7
3.1	Justificación del algoritmo	7
3.2	Diseño del modelo (paso a paso)	7
3.3	Evaluación y optimización	7
3.4	Enlace al modelo	9
4	Análisis No Supervisado 3 — Agrupación sobre samsung.csv	9
4.1	Justificación del algoritmo	9
4.2	Diseño del modelo (paso a paso)	9
4.3	Optimización del número de clusters	10
4.4	Gráficas e interpretación de resultados	11
4.5	Enlace al modelo	12
5	Análisis No Supervisado 4 — Reducción de dimensionalidad sobre comprar_alquilar.csv	12
5.1	Justificación del algoritmo	12
5.2	Diseño del modelo (paso a paso)	12
5.3	Comparación de los dos primeros componentes	13
5.4	Justificación del número de componentes	14
5.5	Enlace al modelo	15
6	Evaluación DE — Algoritmos alternos a SA	15

6.1	DE 1 — Clasificación con Random Forest	15
6.1.1	Justificación del algoritmo	15
6.1.2	Diseño, evaluación y optimización	16
6.2	DE 2 — Regresión con Random Forest	17
6.2.1	Justificación del algoritmo	18
6.2.2	Diseño, evaluación y optimización	18
7	Evaluación AU — Herramienta alternativa (Streamlit)	19
7.1	Justificación de la herramienta	19
7.2	Diseño de la aplicación	19
7.3	Reporte de evaluación y resultados en la app	20
7.4	Capturas de la aplicación	20
7.5	Enlace al repositorio	23
8	Conclusiones	23
9	Anexo — Repositorio del proyecto	24

1. Introducción

1.1. Objetivo

La presente evaluación de la Unidad 2 tiene como objetivo aplicar técnicas de **aprendizaje supervisado** (regresión y clasificación) y **aprendizaje no supervisado** (agrupación y reducción de dimensionalidad) sobre cuatro conjuntos de datos, así como implementar una **herramienta alternativa** a Jupyter Notebook para resolver los ejercicios de las evaluaciones SA y DE.

1.2. Conjuntos de datos

Tabla 1: Conjuntos de datos de la evaluación

Archivo	Descripción	Problema
beisbol.csv	30 equipos de béisbol: bateos y runs	Regresión
breast-cancer.csv	569 casos de cáncer de mama, 30 características y diagnóstico (B/M)	Clasificación
samsung.csv	2,850 días de cotización de la acción Samsung (Close y Volume)	Agrupación
comprar_alquilar.csv	202 registros con 9 variables financieras y decisión comprar/alquilar	Reducción de dimensionalidad

1.3. Repositorio

Todos los notebooks, modelos y reportes se encuentran en el repositorio:

<https://github.com/rmMarioAlberto/evaluacion-u2-extraccion-conocimiento-bd>

Cada sección de este documento incluye el enlace al modelo obtenido en dicho repositorio (carpeta `modelos/` y notebook correspondiente en `notebooks/`).

2. Análisis Supervisado 1 — Regresión sobre beisbol.csv

2.1. Justificación del algoritmo

Se eligió **Regresión Lineal Simple** porque la variable objetivo **runs** es continua y existe un único predictor numérico (**bateos**). Es el modelo más simple e interpretable: la pendiente indica cuántas carreras adicionales produce cada turno al bat extra. Con solo 30 observaciones, un modelo más complejo (árboles, redes) se sobreajustaría con facilidad, por lo que la regresión lineal ofrece una línea de base robusta y auditable.

2.2. Diseño del modelo (paso a paso)

1. **Carga y exploración:** se lee `beisbol.csv`; no hay valores nulos.
2. **Análisis exploratorio:** el diagrama de dispersión muestra una tendencia creciente; la correlación entre `bateos` y `runs` es $r = 0.6106$.
3. **Estrategia de evaluación:** al haber solo 30 observaciones, reservar un conjunto de prueba de 6–9 filas hace el R^2 de prueba inestable. Por ello se evalúa con **validación cruzada** usando **RMSE** (métrica bien definida incluso con pliegues de una muestra): **LeaveOneOut** (LOOCV) y **k-fold** (5 pliegues).
4. **Entrenamiento:** se ajusta el modelo lineal sobre los 30 equipos.
5. **Optimización:** búsqueda de hiperparámetros mediante **GridSearchCV** sobre el grado de una regresión polinomial (1–4).

2.3. Evaluación y optimización

Tabla 2: Métricas del modelo de regresión lineal (`beisbol.csv`)

Métrica	Ajuste completo	Validación cruzada
R^2	0.3729	—
RMSE	64.22	LOOCV: 55.59 / 5-fold: 69.23
MAE	51.67	—

La ecuación ajustada es:

$$\widehat{\text{runs}} = 0.6305 \times \text{bateos} - 2789.2429$$

Búsqueda de hiperparámetros (grado polinomial). El **GridSearchCV** evaluó grados 1 a 4:

Tabla 3: Comparación de grados polinomiales (RMSE de validación cruzada)

Grado	RMSE (CV)
1	69.230
2	69.078
3	68.926
4	69.233

Los grados superiores reducen el RMSE en menos de 0.4 carreras (aproximadamente 0.5%), una mejora marginal que no justifica la complejidad añadida ni el riesgo de sobreajuste. Por parsimonia (principio de Occam) se conserva la regresión lineal simple (grado 1) como modelo final.

2.4. Gráficas e interpretación de resultados




Figure 1: Dispersión del comportamiento de los datos: bateos vs runs. Se observa una tendencia lineal creciente moderada ($r = 0.61$), con varios equipos por encima y por debajo de la recta.




Figure 2: Valores reales contra predichos. Los puntos se concentran alrededor de la línea ideal; la dispersión refleja la capacidad predictiva limitada de una sola variable sobre un conjunto de solo 30 equipos.

Interpretación. La regresión lineal explica el 37.3% de la varianza de las carreras a partir de los turnos al bat ($R^2 = 0.3729$), con un error de predicción de aproximadamente 56–69 carreras según la validación cruzada. La relación es moderada pero real; el tamaño reducido del conjunto es la principal limitación.

2.5. Enlace al modelo

- Notebook: https://github.com/rmMarioAlberto/evaluacion-u2-extraccion-conocimiento-bd/blob/main/notebooks/1_sa_regresion_lineal.ipynb
- Modelo: https://github.com/rmMarioAlberto/evaluacion-u2-extraccion-conocimiento-bd/blob/main/modelos/beisbol_regresion_lineal.pkl

3. Análisis Supervisado 2 — Clasificación sobre breast-cancer.csv

3.1. Justificación del algoritmo

Se eligió el algoritmo de los **k-Vecinos Más Cercanos (k-NN)** porque el conjunto tiene 30 características numéricas continuas y una etiqueta binaria (benigno/maligno). k-NN es un clasificador no paramétrico sencillo e interpretable: clasifica cada muestra según la mayoría de sus k vecinos más cercanos. Permite una búsqueda de hiperparámetros clara (k , pesos y métrica de distancia) y no asume linealidad.

3.2. Diseño del modelo (paso a paso)

1. **Carga y exploración:** 569 muestras, 30 características, sin nulos; balance de clases 357 benignas (B) y 212 malignas (M).
2. **Preprocesamiento:** se separa la variable objetivo (`diagnosis` $\rightarrow$ 1/0) y se elimina el identificador.
3. **Particionado:** 75%/25% estratificado (`random_state=42`).
4. **Escalado:** `StandardScaler` ajustado sobre entrenamiento (k-NN es sensible a la escala).
5. **Optimización:** `GridSearchCV` (5 pliegues) sobre $k \in [1, 15]$, pesos `uniform/distance` y métrica `euclidean/manhattan`.
6. **Entrenamiento final:** k-NN con los mejores hiperparámetros.

3.3. Evaluación y optimización



Mejores hiperparámetros: $k = 6$, pesos `distance`, distancia euclidiana. **Accuracy en validación cruzada:** 0.9695.

Tabla 4: Métricas del clasificador k-NN sobre el conjunto de prueba

	Accuracy	Precision	Recall	F1
k-NN	0.9580	0.9796	0.9057	0.9412

Tabla 5: Reporte de clasificación por clase

Clase	Precision	Recall	F1	Soporte
Benigno	0.95	0.99	0.97	90
Maligno	0.98	0.91	0.94	53

**Figure 3:** Matriz de confusión del clasificador k-NN (test).**Figure 4:** Análisis de sensibilidad al número de vecinos k . El accuracy es máximo cerca de $k = 6$ (línea punteada), valor elegido por el GridSearch.




Figure 5: Proyección PCA (2 componentes) de las clases reales (train) y predichas (test). Se aprecia una separación clara entre benignos y malignos.

3.4. Enlace al modelo

- Notebook: https://github.com/rmMarioAlberto/evaluacion-u2-extraccion-conocimiento-bd/blob/main/notebooks/2_sa_clasificacion_knn.ipynb
- Modelo: https://github.com/rmMarioAlberto/evaluacion-u2-extraccion-conocimiento-bd/blob/main/modelos/breast_knn.pkl

4. Análisis No Supervisado 3 — Agrupación sobre `samsung.csv`

4.1. Justificación del algoritmo

Se eligió **K-Means** porque se busca particionar las observaciones (días de cotización) en grupos homogéneos a partir de características numéricas continuas, sin etiquetas previas. Es el algoritmo de agrupación más utilizado por su sencillez y eficiencia. El número de clusters k se optimizó con el **método del codo** (inercia), el **coeficiente de silueta** y el índice de **Davies-Bouldin**.

4.2. Diseño del modelo (paso a paso)

1. **Carga y exploración:** 2,850 días (2008–2019) con precio de cierre (`Close`) y volumen (`Volume`).
2. **Ingeniería de características:** retorno diario (%), volumen logarítmico y medias móviles de 5 y 20 días; se descartan filas con NaN (quedan 2,831 observaciones).
3. **Escalado:** `StandardScaler` sobre las 6 características.

4. **Optimización de k :** para $k = 2, \dots, 10$ se calculan inercia, silueta y Davies-Bouldin.
5. **Entrenamiento final:** K-Means con el k óptimo.

4.3. Optimización del número de clusters

Tabla 6: Métricas de evaluación para cada k

k	Inercia	Silueta	Davies-Bouldin
2	10604.48	0.4510	0.7953
3	7935.45	0.3794	1.0393
4	5619.45	0.3916	0.8201
5	4545.44	0.3933	0.8592
6	3848.05	0.3818	0.8339
7	3442.56	0.3330	0.8964
8	3193.31	0.3409	0.8630
9	2947.50	0.3010	1.0045
10	2741.43	0.2866	1.0652




Figure 6: Método del codo (inercia) y coeficiente de silueta para $k = 2, \dots, 10$. La silueta es máxima en $k = 2$ (0.4510).

Selección de k : el coeficiente de silueta y el índice de Davies-Bouldin coinciden en que el mejor número de clusters es **$k = 2$** .

4.4. Gráficas e interpretación de resultados




Figure 7: Serie temporal del precio (línea) y volumen (área) de la acción Samsung.




Figure 8: Clusters obtenidos por K-Means ($k = 2$) sobre las características escaladas; los centroides se marcan con X.



Figure 9: Perfil promedio de cada cluster.

Interpretación. El cluster 0 (2,196 días) agrupa días con precio medio de $\approx 21,249$ y volumen alto (≈ 17.2 millones); el cluster 1 (635 días) agrupa días con precio medio de $\approx 45,631$ y volumen menor (≈ 11.8 millones). Es decir, los clusters separan *periodos de precio bajo-alto volumen* de *periodos de precio alto-bajo volumen*, revelando dos regímenes de mercado distintos.

4.5. Enlace al modelo

- Notebook: https://github.com/rmMarioAlberto/evaluacion-u2-extraccion-conocimiento-bd/blob/main/notebooks/3_ns_agrupacion_kmeans.ipynb
- Modelo: https://github.com/rmMarioAlberto/evaluacion-u2-extraccion-conocimiento-bd/blob/main/modelos/samsung_kmeans.pkl

5. Análisis No Supervisado 4 — Reducción de dimensionalidad sobre comprar_alquilar.csv

5.1. Justificación del algoritmo

Se eligió **Análisis de Componentes Principales (PCA)**, el método de reducción de dimensionalidad más estándar: proyecta los datos a direcciones ortogonales que capturan la mayor varianza posible. Permite visualizar 9 variables predictoras en 2D, elimina redundancia y facilita modelos posteriores. La elección del número de componentes se justificó con la **varianza explicada acumulada** (umbral del 95%) y el criterio de **Kaiser** (autovalores > 1).

5.2. Diseño del modelo (paso a paso)

1. **Carga y exploración:** 202 registros, 9 variables predictoras y la variable objetivo comprar.
2. **Comparación sin/con escalado:** se calcula PCA con 2 componentes sobre los datos brutos y sobre los datos estandarizados.

3. **Justificación del número de componentes:** se ajusta PCA completo y se calculan la varianza explicada y su acumulada.
4. **Reducción final:** proyección con el número de componentes que captura al menos el 95% de la varianza.

5.3. Comparación de los dos primeros componentes




Figure 10: PCA sin escalado: PC1 concentra el 99% de la varianza porque las variables de mayor magnitud (p. ej. vivienda, desviación 136,371) dominan.




Figure 11: PCA con escalado (StandardScaler): PC1 (29.9%) y PC2 (23.3%) distribuyen mejor la varianza entre todas las variables.

Importancia del escalado: sin escalar, PC1 explica el 99% de la varianza porque queda dominada por vivienda; con escalado, PC1 y PC2 explican 29.9% y 23.3%, respectivamente, y todos los puntos se distribuyen de forma más informativa. Por eso el análisis final usa datos escalados.

5.4. Justificación del número de componentes

Tabla 7: Varianza explicada (PCA con escalado)

Componente	Varianza	Acumulada	Componente	Varianza acumulada
1	0.299	0.299	6	0.909
2	0.233	0.532	7	0.950
3	0.117	0.649	8	0.980
4	0.107	0.756	9	1.000
5	0.096	0.852		




Figure 12: Scree plot y varianza acumulada. Se requieren 7 componentes para alcanzar el umbral del 95%.

Decisión: se eligen $n = 7$ componentes, que capturan el 95.02% de la varianza total, reduciendo los datos de 9 a 7 dimensiones. (El criterio de Kaiser sugiere 3 componentes por autovalor > 1 ; el umbral del 95% es la elección adoptada por ser el más común en la práctica.)




Figure 13: Cargas (loadings) de los dos primeros componentes: muestran qué variables contribuyen más a cada componente.

5.5. Enlace al modelo

- Notebook: https://github.com/rmMarioAlberto/evaluacion-u2-extraccion-conocimiento-bd/blob/main/notebooks/4_ns_pca.ipynb
- Modelo: https://github.com/rmMarioAlberto/evaluacion-u2-extraccion-conocimiento-bd/blob/main/modelos/comprar_alquilar_pca.pkl

6. Evaluación DE — Algoritmos alternos a SA

La evaluación DE solicita implementar un algoritmo de clasificación y uno de regresión *distintos* a los usados en SA, sobre los mismos conjuntos de datos.

6.1. DE 1 — Clasificación con Random Forest

6.1.1. Justificación del algoritmo

Se eligió **Random Forest** como alternativo al k-NN de SA. Es un ensamble de árboles de decisión (bagging) que reduce la varianza y el sobreajuste, maneja bien datos tabulares con muchas características y no requiere escalado. Permite además medir la importancia de las características.

6.1.2. Diseño, evaluación y optimización

Hiperparámetros óptimos (GridSearchCV): $n_estimators = 100$, $max_depth =$ sin límite, $min_samples_split = 2$. Accuracy en CV: 0.9648.

Tabla 8: Métricas de Random Forest sobre el conjunto de prueba

	Accuracy	Precision	Recall	F1
Random Forest	0.9650	1.0000	0.9057	0.9505
k-NN (SA)	0.9580	0.9796	0.9057	0.9412




Figure 14: Matriz de confusión del Random Forest (test).




Figure 15: Importancia de las características: las más relevantes son worst_area, worst_concave_points y worst_perimeter.




Figure 16: Ejemplo de un árbol dentro del bosque (profundidad 3) graficado con plot_tree.

Enlace al modelo:

- Notebook: https://github.com/rmMarioAlberto/evaluacion-u2-extraccion-conocimiento-bd/blob/main/notebooks/5_de_clasificacion_randomforest.ipynb
- Modelo: https://github.com/rmMarioAlberto/evaluacion-u2-extraccion-conocimiento-bd/blob/main/modelos/breast_randomforest.pkl

6.2. DE 2 — Regresión con Random Forest

6.2.1. Justificación del algoritmo

Se eligió **Random Forest Regressor** como alternativo a la regresión lineal de SA. Al ser un ensamble de árboles, puede capturar relaciones no lineales entre **bateos** y **runs** sin asumir una forma paramétrica.

6.2.2. Diseño, evaluación y optimización

Hiperparámetros óptimos (GridSearchCV): $n_estimators = 50$, $max_depth =$ sin límite, $min_samples_leaf = 4$.

Tabla 9: Métricas de Random Forest Regressor (ajuste completo)

Modelo	R^2	RMSE	MAE
Random Forest	0.4060	62.50	47.53
Regresión Lineal (SA)	0.3729	64.22	51.67

Validación cruzada (RMSE): LOOCV = 59.08, 5-fold = 76.27. El Random Forest obtiene un R^2 ligeramente superior al lineal en el ajuste completo, aunque con validación cruzada su RMSE es comparable o ligeramente mayor, lo que confirma que la ganancia de complejidad es marginal con tan pocas observaciones.




Figure 17: Dispersión del comportamiento de los datos (bateos vs runs).




Figure 18: Valores reales contra predichos para el Random Forest.

Enlace al modelo:

- Notebook: https://github.com/rmMarioAlberto/evaluacion-u2-extraccion-conocimiento-bd/blob/main/notebooks/6_de_regresion_randomforest.ipynb
- Modelo: https://github.com/rmMarioAlberto/evaluacion-u2-extraccion-conocimiento-bd/blob/main/modelos/beisbol_randomforest.pkl

7. Evaluación AU — Herramienta alternativa (Streamlit)

7.1. Justificación de la herramienta

La evaluación AU solicita resolver los ejercicios de SA y DE con una **herramienta alternativa a Jupyter Notebook**. Se eligió una **aplicación web interactiva con Streamlit** (`app/streamlit_app.py`), que permite:

- ejecutar los seis modelos desde una interfaz gráfica,
- visualizar métricas y gráficas de forma interactiva en pestañas,
- demostrar el uso de una herramienta de despliegue de ciencia de datos distinta al entorno de notebooks.

7.2. Diseño de la aplicación

La aplicación carga los cuatro conjuntos de datos y organiza la solución en seis pestañas (una por ejercicio): **SA Regresión (Lineal)**, **SA Clasificación (k-NN)**, **NS Agru-**

pación (K-Means), NS Reducción (PCA), DE Clasificación (Random Forest) y DE Regresión (Random Forest). Cada pestaña muestra la justificación, el pre-procesamiento, las métricas de evaluación y las gráficas correspondientes, reutilizando los hiperparámetros óptimos encontrados en los notebooks.

7.3. Reporte de evaluación y resultados en la app

La aplicación reproduce las métricas de los notebooks:

Tabla 10: Métricas mostradas en la app Streamlit

Ejercicio	Métrica principal	Valor
SA Regresión (Lineal)	R^2	0.3729
SA Clasificación (k-NN)	Accuracy	0.9580
NS Agrupación (K-Means)	Silueta	0.4510
NS Reducción (PCA)	Varianza (n=7)	95.02%
DE Clasificación (RF)	Accuracy	0.9650
DE Regresión (RF)	R^2	0.4060

7.4. Capturas de la aplicación



Figure 19: App Streamlit — pestaña 1: SA Regresión Lineal (beisbol).

**Figure 20:** App Streamlit — pestaña 2: SA Clasificación k-NN (breast-cancer).**Figure 21:** App Streamlit — pestaña 3: NS Agrupación K-Means (samsung).

Evaluación Unidad 2 — Extracción de Conocimiento de Base de Datos

Herramienta alternativa a Jupyter Notebook (Streamlit) - SA y DE

Materia: Extracción de Conocimiento de Base de Datos — Docente: Filiberto Ruíz Hernández

Alumno: Mario Alberto Ramírez Martínez (2023371044) — UTEQ - Ingeniería en Gestión de Desarrollo de Software

1 - SA Regresión (Lineal) 2 - SA Clasificación (k-NN) 3 - NS Agrupación (K-Means) 4 - NS Reducción (PCA) 5 - DE Clasificación (Random Forest) 6 - DE Regresión (Random Forest)

4. NS — Reducción de dimensionalidad PCA sobre comprar_alquilar.csv

Análisis de Componentes Principales: comparación de los dos primeros componentes sin y con escalado, y justificación de $n=7$ componentes (95% de varianza).

	ingresos	gastos_comunes	pagos_coche	gastos_otros	ahorros	vivienda	estado_civil	hijos	trabajo	comprar
0	6000		1000	0	600	50000	400000	0	2	2
1	6745	944	123	429	43240	636897	1	3	6	0
2	6455	1033	98	795	57463	321779	2	1	8	1
3	7098	1278	15	254	54506	660933	0	0	3	0
4	6167	863	223	520	41512	348932	0	0	3	1




Figure 22: App Streamlit — pestaña 4: NS Reducción PCA (comprar_alquilar).

Evaluación Unidad 2 — Extracción de Conocimiento de Base de Datos

Herramienta alternativa a Jupyter Notebook (Streamlit) - SA y DE

Materia: Extracción de Conocimiento de Base de Datos — Docente: Filiberto Ruíz Hernández

Alumno: Mario Alberto Ramírez Martínez (2023371044) — UTEQ - Ingeniería en Gestión de Desarrollo de Software

1 - SA Regresión (Lineal) 2 - SA Clasificación (k-NN) 3 - NS Agrupación (K-Means) 4 - NS Reducción (PCA) 5 - DE Clasificación (Random Forest) 6 - DE Regresión (Random Forest)

5. DE — Clasificación Random Forest sobre breast-cancer.csv

Alterno al k-NN de SA: Random Forest (100 árboles).

Accuracy 0.965 Precision 1.0 Recall 0.9057 F1 0.9505




Figure 23: App Streamlit — pestaña 5: DE Clasificación Random Forest.

Evaluación Unidad 2 — Extracción de Conocimiento de Base de Datos

Herramienta alternativa a Jupyter Notebook (Streamlit) - SA y DE

Materia: Extracción de Conocimiento de Base de Datos — Docente: Filiberto Ruíz Hernández

Alumno: Mario Alberto Ramírez Martínez (2023371044) — UTEQ - Ingeniería en Gestión de Desarrollo de Software

1 - SA Regresión (Lineal) 2 - SA Clasificación (k-NN) 3 - NS Agrupación (K-Means) 4 - NS Reducción (PCA) 5 - DE Clasificación (Random Forest) 6 - DE Regresión (Random Forest)

6. DE — Regresión Random Forest sobre beisbol.csv

Alternativo a la regresión lineal de SA; Random Forest Regressor (50 árboles).

equipos	bateos	runs
0 Texas		5609
1 Boston		5710
2 Detroit		5563
3 Kansas		5672
4 St.		5532
5 New_Y.		5600
6 New_Y.		5518
7 Milwaukee		5447
8 Colorado		5544
9 Houston		5598

R²
0.7852

RMSE
37.5817

MAE
29.2557

Valores reales vs predichos — Random Forest



Figure 24: App Streamlit — pestaña 6: DE Regresión Random Forest.

7.5. Enlace al repositorio

Aplicación: https://github.com/rmMarioAlberto/evaluacion-u2-extraccion-conocimiento-bd/blob/main/app/streamlit_app.py

8. Conclusiones

- Regresión (SA y DE).** Sobre `beisbol.csv` la regresión lineal explica el 37.3% de la varianza de las carreras a partir de los turnos al bat; el Random Forest la mejora marginalmente (40.6%). Con solo 30 observaciones, la validación cruzada con RMSE resultó esencial para obtener estimaciones estables.
- Clasificación (SA y DE).** Sobre `breast-cancer.csv`, tanto k-NN (accuracy 0.958) como Random Forest (0.965) alcanzan un desempeño excelente; la optimización de hiperparámetros mejoró los resultados y las matrices de confusión muestran pocos falsos negativos (2 en k-NN, 5 en RF).
- Agrupación.** K-Means encontró dos regímenes de mercado en la serie de Samsung, validados por silueta (0.451) y Davies-Bouldin (0.795).
- Reducción de dimensionalidad.** El escalado es determinante: sin él PC1 concentra el 99% de la varianza. Con `StandardScaler` se seleccionaron 7 componentes (95% de varianza).
- Herramienta alternativa.** La aplicación Streamlit resuelve los seis ejercicios de forma interactiva, cumpliendo el requisito de AU con una herramienta distinta a Jupyter Notebook.

9. Anexo — Repositorio del proyecto

<https://github.com/rmMarioAlberto/evaluacion-u2-extraccion-conocimiento-bd>




Figure 25: Captura del repositorio que contiene los notebooks, modelos, reporte y aplicación de la evaluación.